

麒麟：一种包含应用级用户会话的多模态信息检索数据集

Jia Chen[†]
小红书公司
chenjia2@xiaohongshu.com

Qian Dong[†]
清华大学
dq22@mails.tsinghua.edu.cn

Haitao Li
清华大学
liht22@mails.tsinghua.edu.cn

Xiaohui He
小红书公司
manyou@xiaohongshu.com

Yan Gao
小红书公司
yadun@xiaohongshu.com

Shaosheng Cao
小红书公司
shelsoncao@gmail.com

Yi Wu
小红书公司
xiaohui@xiaohongshu.com

Ping Yang
小红书公司
jiadi@xiaohongshu.com

Chen Xu
小红书公司
chenlin1@xiaohongshu.com

Yao Hu
小红书公司
yaoohu@gmail.com

Qingyao Ai
清华大学
aiqy@tsinghua.edu.cn

刘亦群 清华
大学
yiqunliu@tsinghua.edu.cn

摘要

用户生成内容（UGC）社区，尤其是包含多模态内容的社区，通过将视觉和文本信息整合到搜索结果（或项目）中，显著提升了用户体验。近年来，如何在融合搜索与推荐（S&R）服务的复杂系统中改善用户体验，已受到学术界和工业界的广泛关注。然而，高质量数据集的缺乏严重制约了多模态S&R领域的研究进展。为满足开发更优S&R服务日益增长的需求，本文提出了一种全新的多模态信息检索数据集——Qilin。该数据集采集自小红书，这是一个拥有超过3亿月活跃用户的热门社交平台，平均搜索渗透率超过70%。与现有数据集相比，Qilin提供了涵盖图像-文本笔记、视频笔记、商品笔记和直接答案等异构结果的完整用户会话数据，有助于在多样化任务场景下推动先进多模态神经检索模型的发展。为了更好地建模用户满意度并支持对异质性用户行为的分析，我们还收集了大量应用层面的上下文信号和真实的用户反馈。值得注意的是，麒麟系统包含了用户偏好的答案及其对应的引用结果，这些数据来自触发深度问答（DQA）模块的搜索请求。这不仅有助于训练和评估检索增强生成（RAG）流程，还能探索该模块对用户搜索行为的影响。通过全面的分析与实验，

我们提供了有趣的发现和见解，以进一步改进搜索与推荐系统。我们希望麒麟未来能为多模态内容平台在搜索与推荐服务方面的发展做出重要贡献。

ACM参考格式：

贾 Chen[†]，钱 Dong[†]，李海涛，何晓辉，高艳，曹少生，吴毅，杨平，徐晨，胡耀，艾青耀，刘一琼。2025年。麒麟：一种具有应用级用户会话的多模态信息检索数据集。载于ACM会议论文集（Conference' 17）。ACM，美国纽约州纽约市，共11页。https://doi.org/10.1145/nnnnnnn.nnnnnnn

1 引言

如今，搜索引擎和推荐系统在在线内容平台中发挥着至关重要的作用。除了文本内容外，主流的用户生成内容（UGC）社区通常以单栏或双栏形式展示图文结合的内容或视频[19, 65]。这些多模态内容有助于用户更便捷地获取所需信息，例如，制作提拉米苏时每一步都配有图片的说明，甚至提供整个过程的视频，能更直观地帮助用户还原风味。因此，如何将多模态元素融入检索器对于提升系统性能至关重要。然而，目前大多数面向通用搜索或推荐任务的数据集主要包含文本信息或统计上密集的特征，这不利于深入研究更优质的多模态搜索与推荐（S&R）服务。

为了提升特定移动应用的用户满意度，对APP层面的用户行为进行深入分析至关重要。随着用户信息需求日益复杂，他们可能在短时间内连续发出一系列相关查询，以期获得更理想的结果，即会话搜索[2, 10, 11]。在其他情况下，用户也可能受到推荐结果或查询建议模块[9, 42]的启发，通过搜索系统探索相关主题。用户的APP级行为轨迹多种多样，包含丰富的上下文信息，其中一些上下文或因素可能至关重要。

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than ACM must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.




图1: 小红书在搜索与推荐服务中采用双栏结果列表, 可检索图像文本、视频和商业笔记等异构内容。搜索系统配备了DQA模块, 为用户提供直接答案, 同时还设有多种模块, 以激发用户探索他们可能感兴趣的各话题。

在评估用户满意度或长期留存时, 例如Ozertem等人[42]发现, 除了点击信号外, 用户的重新提问行为也可作为衡量满意度的有效代理指标。因此, 除了单次请求之外, 我们还应关注会话层面的信号, 如重新提问和再次访问行为、用户搜索意图来源, 以及应用层面用户行为转换模式($S \rightarrow R$ 或 $R \rightarrow S$), 以更准确地评估用户对整个应用的长期满意度。

由于多模态场景中信息呈现形式的多样性, 传统的用户行为分析结果可能不再适用。在具有异构功能模块的多模态搜索与推荐系统中预测用户满意度仍面临挑战。例如, 现代搜索引擎通常集成深度问答(DQA)模块, 为用户提供简洁直接的答案。典型的DQA模块通过检索增强生成(RAG)流程运行[20, 52], 即先检索相关文档, 再提示大语言模型进行一致性检查和内容总结。当直接答案出现时, 用户的浏览行为将受到显著影响, 例如他们可能更关注顶部结果, 而较少与其它自然排序结果互动[58]。事实上, DQA模块对用户满意度和留存率的影响仍鲜有研究。为了更好地评估RAG模块对用户感知体验的影响, 学术界强调需要构建一个包含用户对DQA模块真实反馈以及他们在使用该模块前后上下文行为数据的数据集。

为阐明上述问题, 我们提出了一种全新的多模态数据集Qilin, 该数据集包含在多种场景(包括搜索、问答和推荐)下大规模的APP级用户信息发现会话。所有用户会话均来自小红书¹, 这是一个广受欢迎的社交平台, 也是中国最大的生活方式搜索引擎, 拥有超过3亿月活跃用户, 搜索渗透率超过70%。与其他平台不同, 小红书提供异构结果, 如图文笔记、视频笔记、商业笔记

和直接答案(如图1所示), 这对搜索和推荐系统的优化带来了挑战。综上所述, Qilin的主要创新点如下:

据我们所知, 麒麟是首个从社交媒体平台收集异构结果的实用多模态搜索与推荐数据集。真实用户行为和多模态内容特征有助于在多种任务场景下训练复杂的神经网络架构, 甚至大语言模型。

除了请求和商品特征等侧边信息外, 我们还包含丰富的应用级上下文信号(如查询来源、请求历史、时间戳、位置等)以及用户对整个系统的多种反馈。这些信号对于深入研究用户状态转换、重复访问和查询重述, 进而建模用户满意度或长期留存至关重要。

对于触发DQA模块的搜索请求, 我们进一步收集用户偏好的答案及其所引用的结果, 作为该特定查询下的正样本实例。因此, Qilin不仅可以作为训练或评估RAG模块的基准, 还可用于探索该模块对用户行为带来的影响。

为便于本工作的复现, Qilin的所有资源、代码实现及相关实验细节均已发布在下方的仓库中。

2 相关工作

2.1 多模态信息检索

多模态信息检索已受到信息检索(IR)、计算机视觉(CV)和多媒体领域的广泛研究。为便于理解, 我们分别从方法和任务类型两个方面对相关研究进行了系统分类。

通常, 多模态检索方法可分为三类: 1) 基于表示学习的方法[6, 18, 28, 51, 56, 68], 2) 基于模态融合或交互的方法[23, 32, 61], 以及3) 混合建模方法[23, 33, 35, 44]。基于表示学习的方法旨在通过哈希函数将某一模态(通常是图像)映射到二进制汉明空间[36, 68], 或将其编码到潜在的语义空间中[6, 18]。通常, 基于哈希的方法存储成本较低, 在实时系统中效率较高[64, 67]。相比之下, 基于语义的方法更侧重于利用深度神经网络(DNNs)进行模态理解与跨模态匹配。尽管DNNs相比传统方法具有更好的泛化能力[66], 但融合模态与交互的架构通常能实现更高的性能。为解决模态内推理与跨模态对齐问题, Qu等人[44]提出了一种带有路由机制的动态模态交互网络。因此, 将模态表示与多模态特征交互相结合的混合建模方法往往优于单一建模方法。

按任务类型划分, 相关文献可分为跨模态检索[18, 37, 56]和多模态检索[6, 23, 28]。广义上, 多模态检索指的是包含非文本模态(如图像、视频或音频)的查询或结果的检索请求。特别地, 跨模态检索通常涉及单模态查询。

¹ Known in English as rednote, official site: www.xiaohongshu.com.

² <https://github.com/RED-Search/Qilin>

以及不同模态下的结果，例如文本到图像检索[18, 48, 54]、文本到视频检索[32, 53]、图像到字幕检索[18, 25, 37]等。Balaneshein-kordan 和 Kotov [6] 通过跨模态对齐和统一表示学习联合建模文本-图像嵌入空间。他们的方法能够处理跨模态任务（文本到图像， $T \rightarrow I$ ）和多模态任务（ $I \rightarrow IT$, $T \rightarrow IT$ ）。除了单次查询会话外，研究人员还致力于优化多查询会话[34, 61]。例如，Xie 等人[61]通过利用历史查询和交互图像等会话上下文来增强图像搜索。此外，Liu 等人[34]采用异构图神经网络（HGN）来建模多查询产品搜索中的查询内、查询间以及跨模态信息传播。实验结果表明，会话级上下文在用户意图建模和多模态信息匹配中具有重要作用。

异质用户行为分析

分析异质性用户行为，并在相应场景中进一步挖掘特定模式，对于用户满意度建模和系统优化至关重要。为研究垂直搜索场景中的用户行为，研究人员分别对视觉搜索进行深入的日志分析[13]，或对图像搜索开展眼动追踪研究[60]，其发现有助于改进相应的排序算法和系统布局。此外，大量研究探讨了用户在与检索系统交互过程中的意图转变[9, 46, 57]。例如，Chen等人[9]通过实地研究，从改写原因、界面和灵感来源等细致层面，探究用户查询重述行为的差异。尽管在实践中直接建模用户留存具有挑战性，Wu等人[57]发现频繁回访可能表明更强的用户粘性。尽管这些研究为系统优化提供了有价值的见解，但它们主要聚焦于S&R系统中的单一组件。由于一项服务可能显著影响用户在另一项服务中的行为（例如，部分搜索查询源于推荐结果中的建议），我们为麒麟收集了应用级别的用户会话数据。这些会话包含用户对搜索、推荐和DQA服务的反馈，以及会话ID、搜索来源和时间戳等上下文信息，以便更好地分析用户在各服务内部及跨服务的行为轨迹。

2.3 搜索与推荐数据集

数据集是改进和评估检索系统的基础。迄今为止，大多数广泛使用的搜索[41, 59]、推荐[19, 38]以及搜索与推荐（S&R）[4, 31, 49]数据集通常仅包含文本内容或基于数值的项目特征，这对于构建更优的多模态检索系统而言存在不足。一个例外是电子商务 45]，在该场景中系统需要同时利用商品标题和图像进行排序。在这方面，Miao等人[40]和Gong等人[22]提出了包含淘宝商品短标题和图像的数据集。除上述数据集外，还开发了UniIR[55]和Flickr30K[43]等多模态检索数据集。这些数据集主要包含如“找一张人骑马的图片”这类事实性查询，其特点是意图明确，且通常具有真实匹配结果。然而，在实际的搜索与推荐场景中，用户意图往往




图2：麒麟的数据构建流程。前端日志与抽样用户ID进行关联，以获得数据集的主体部分。随后，我们从多个数据库中收集请求、用户和笔记的相关特征。最后，所有内容特征均经过大语言模型和人工专家的严格筛选。

具有歧义性。尽管这些数据集对于图像-文本模态对齐很有价值，但若直接用于通用检索系统的训练，则存在不足。此类系统需要能够捕捉事实类和非事实类查询背后的复杂用户意图，并相应地检索出相关结果。

在这方面，麒麟数据集包含大量非事实性查询及其多模态结果，具有相当高的挑战性。此外，收集到的用户会话中包含丰富的文本和图像内容，有利于上述各类方法的应用，并有助于复杂检索场景的研究。这种复杂性不仅对多模态意图理解构成挑战，也对会话级别的跨模态匹配提出了更高要求。

3 麒麟数据集

在本节中，我们将深入探讨麒麟数据集的细节。首先，我们详细阐述数据预处理与构建流程；接着，介绍麒麟的数据结构，以便清晰了解其包含的信息内容；最后，讨论麒麟在搜索、推荐、检索增强生成等多种场景下可能支持的研究任务。

3.1 数据构建

如图2所示，麒麟的整体数据构建流程包括以下几个步骤：用户采样、前端日志关联、特征收集和过滤。

用户抽样。为了尽可能包含更多的应用层面上上下文信息，我们基于用户ID而非页面浏览量（PV）对原始数据进行随机抽样。所有用户根据其交互频率被划分为不同的参与等级。我们首先从2024年11月27日在应用内表现出核心交互行为的全部用户中，随机抽取了1.5万名非垃圾用户。这些用户在与应用互动时展现出多样的行为模式。然而，上述大部分搜索请求并未触发DQA模块。为支持针对DQA的深入研究，我们进一步筛选出同一天内明确与该模块发生交互的约3,000名用户。最终，我们获得了一份576个用户ID的合并列表。

前端日志关联。接下来，我们将特定用户ID与前端日志进行关联，以获取请求级别的信息和用户反馈。此处仅使用同一天的日志来控制最终数据量。对于每个推荐请求，我们收集所有展示的

结果包含其位置、时间戳以及五种用户反馈信号，例如点击、点赞、评论等。由于部分结果为视频笔记，我们还将观看时长作为隐式反馈标签进行记录。除上述信息外，一次搜索请求还包含查询词及查询关键词的来源。查询来源记录当前查询所来自的界面类型。对于具有直接DQA答案曝光的特殊请求，我们还会保留答案内容、所引用的结果笔记ID，以及四个反馈标签（例如用户是否喜欢该答案）。

所有请求均可通过会话ID、请求ID和用户ID进行识别，其中会话包含用户从打开APP到关闭期间的所有请求。基于这些标识符以及交互信号、接口和时间戳，我们可以轻松还原应用层面的用户轨迹，并进一步分析其在多个服务中的行为模式。此外，诸如曝光位置等上下文信息，有助于研究无偏排序 [7] 和点击模型[11, 12, 30]。

特征集合。请求和反馈标签构成了我们数据集的核心部分。接下来，我们将请求与笔记特征表和用户特征表进行关联，以支持复杂搜索或推荐模型的训练。对于每条笔记，我们包含标题、内容、封面以及非封面图片ID等字段。需要注意的是，其中有一定比例为视频笔记（约占20%~40%），我们提取视频的关键帧作为图像数据，以压缩最终数据量并保护用户隐私。此外，我们还包含笔记类型、视频时长、多粒度分类体系等基本信息，以及印象数、点击数等30个统计密集型特征。对于所有用户，我们提供人口统计特征（如性别、年龄）和40个加密的稠密特征。为了进一步提升会话搜索或上下文感知的搜索与推荐排序中的用户建模效果，我们额外收集了用户发起特定请求前最近点击的20条笔记ID。

数据过滤。为了在保障数据安全的同时高效利用数据，过滤算法应能够排除明显不安全的内容，同时尽可能保留有效信息。因此，我们通过详细指令引导大语言模型（LLM）根据文档的标题和内容对安全性进行分类。用于文本和图像过滤的模型分别为Qwen2.5-14B-Instruct [63] 和 Qwen2-VL-7B-Instruct [62]。后者是一种支持图像输入的多模态大语言模型，在多种视觉理解基准测试中均取得了最先进的性能。如表1所示，我们指出了四类应严格排除的文本内容。图像过滤所使用的提示语与文本类似，但包含更多规则。除上述四种类型外，我们还要求LLM判断图像中是否包含真实的人脸。LLM不仅需提供安全标签，还需对检测到的图像给出简短的文字描述。首先，我们根据输出标签过滤掉所有包含一个或多个肖像的图像。为进一步保护用户隐私，我们使用另一款参数数量为140亿的纯文本大语言模型，根据描述对剩余图像进行分类。随后，我们从中选取3000张图像，并邀请三位专家复核该子集是否包含任何轻微的不安全内容。此过程重复多次，直至人工审核通过。最终，我们获得了一个包含1, 983, 938条注006，181张图像的数据集。

表1：用于筛选文本和图像数据的提示语。

模型：Qwen2.5-14B-Instruct（Qwen2-VL-7B-Instruct）
提示前缀： 假设你是一名文本（或图像）内容安全审核员，请检查以下文本（或图像），并判断其中是否包含任何违法或敏感信息：
1. 色情/淫秽：包含露骨的性描写、淫秽语言等； 2. 暴力：包含血腥、恐怖、极端暴力等； 3. 政治人物：提及或讨论与政治人物相关的信息； 4. 普通个人的个人信息：包括姓名、身份标识、联系方式、地址等隐私信息； 5. 肖像：包含任何真实人类的面部。请注意，虚拟角色（如动画、漫画或游戏角色）的面部不属于肖像；附加说明：
★ 广告内容不视为违法或敏感信息。 ★ 提及公众人物（如演员、歌手、企业家等）不视为违法或敏感信息，除非是政治人物。
★ 仅当文本明确包含指定的非法或敏感内容时返回 True，否则返回 False。
★ 任何表情符号都不是色情内容。 ★ 正常的恋爱相关内容或性教育内容不被视为色情；但如果内容过于露骨或详细，则属于色情。
★ 表达负面情绪的行为，若不伴随暴力内容，则不应被归类为暴力行为。
★ 不要过于严格，因为将一些小问题标记为违法或敏感内容可能导致误判。如果不确定，可以不将其标记为违法或敏感内容。只有在非常确定的情况下，才将其标记为正面实例并返回True。
待检查的文本（图片）：[
提示后缀： 请仅返回“True”或“False”，无需任何解释。

3.2 统计与数据架构

通常情况下，麒麟数据集包含来自15,482名用户的APP级会话。表2给出了麒麟与现有搜索与推荐（S&R）数据集（Amazon [24, 39]、京东搜索 [31]、KuaiSAR [49]）之间基本统计信息的对比。在这些数据集中，仅有Amazon可勉强用于多模态S&R系统的研究。然而，它仅提供源自商品元数据的伪查询，由于缺乏真实用户搜索行为，可能影响实验结果的可靠性。此外，Amazon数据集中的商品标题和图片还需额外爬取，增加了实验成本。另一方面，京东搜索和KuaiSAR仅提供匿名化的内容（即加密的词ID序列），这可能导致模型效果难以解释。幸运的是，小红书拥有一个开放的社区，蕴含丰富的用户生成内容（UGC），旨在促进人际交流与互助。为确保数据集的完整性，我们在经过严格筛选后，发布了原始笔记内容（标题+正文+图片）。

麒麟以表格形式组织，如表3所示。前三行为骨干表，包含每次搜索或推荐请求的基本信息。此外

表2：麒麟与现有搜索与推荐数据集的对比。注意，亚马逊的数据为伪查询。京东搜索和KuaiSAR仅提供匿名化商品内容。除搜索与推荐外，麒麟还包含用户在DQA上的行为数据。

财产	亚马逊	京东搜索	快搜	麒麟
# 用户	192,403	173,831	25,877	15,482
# 物品	63,001	12,872,736	6,890,707	1,983,938
# 查询	3,221	171,728	453,667	57,188 ¹
# 操作	1,689,188	26,667,260	19,664,885	2,498,594
# 图片 ²	?	—	—	5,006,181
DQA 信息	×	×	×	√
商品描述	标题+评论	匿名	匿名	标题+正文

麒麟提供了2, 932个触发DQA模块的查询子集。
亚马逊的2张图片需按需抓取，因此此处无统计。

表3：麒麟的数据结构

表格	关键	字段
搜索	搜索ID	查询、会话ID、用户ID、最近点击的20个笔记ID、查询来源（1-8）、搜索结果详情（列表，每个元素封装为{笔记ID、位置、时间戳、六个参与标签}，按时间戳升序排列）、DQA详情（若触发）；
回收	请求ID	会话ID、用户ID、最近点击的20个笔记ID、推荐结果详情（包含封装元素的列表，同上）；
DQA	搜索ID	所有搜索字段、回答内容、引用的笔记ID以及四个用户参与标签；
用户	用户ID	性别、平台、年龄、粉丝数、关注数、40个加密密集特征；
注意	笔记编号	笔记类型、笔记标题、笔记内容、图片ID列表 ³ 、视频时长、视频高度、视频宽度、图片数量、内容长度、商业标识、一级/二级/三级分类ID、30项统计特征（例如每月展示量或点击量）；

对于视频笔记，我们通过从关键帧中等距采样来选择图像。

我们还收集用户最近点击的20个笔记ID，以支持短期用户建模。与现有的随机缺失数据集[19]不同，我们保留了搜索和推荐中各个位置的所有曝光结果。当我们知道某个项目是否已被查看时，便无需保留高密度的用户-项目交互数据。二元反馈标签包括点击以及四种互动行为：点赞（点击图1中的心形图标）、收藏（点击图1中的星形图标）、评论和分享。由于这些互动行为较为稀疏，因此我们将观看时长（单位为秒）作为模型训练的标签。

对于触发DQA模块的搜索请求，我们会记录答案内容、所引用的笔记以及相应的用户反馈。由于直接答案会显示在结果页面的顶部，我们假设所有用户都已浏览过这些答案。为了进一步区分用户对答案满意度的细微差异，我们收集了用户在DQA模块上的四种行为：1) 用户是否点赞该答案；2) 用户是否点击了参考文献的上标；3) 用户是否点击了答案正文；4) 用户是否点击了聚合体验标签（以展开构成最终答案的相关段落）。基于引用的笔记和用户偏好的答案，我们可以轻松训练一个大语言模型。

表4：麒麟支持的潜在任务。

场景	任务
搜索	点击率预测、点击模拟、无偏排序学习、多模态搜索、上下文感知排序、会话搜索、面向网页搜索的（后）预训练、通过推荐提升搜索效果、RAG预训练、RAG评估、多模态RAG、查询性能预测等；
回收	基于内容的推荐、多模态推荐、会话推荐、无偏推荐、查询（意图）推荐、通过搜索增强推荐等；
通用	多任务学习、多场景学习、异构用户行为分析、多模态对齐、多模态大语言模型作为评判者、缩放定律拟合等；

在RAG流水线中评估其性能。此外，研究人员还可以探究在有DQA模块的搜索场景下用户行为的差异。

为了便于训练各种方法，我们为用户和笔记收集了丰富的基于内容和基于ID的辅助特征。工业界中的检索方法大致可分为两类。第一类方法通常采用金字塔架构，拥有大量稀疏的ID嵌入参数，但特征交互部分权重较轻，例如DCN-V2 [50]等CTR模型。这类模型通常收敛速度快、推理效率高，但由于语义表示较浅，泛化能力较差。相反，基于内容的方法仅使用词嵌入，并借助深度网络进行表征学习和特征交互，例如预训练模型[16]。这类方法对未见数据更具鲁棒性，但部署时需要大量的在线计算资源。考虑到上述问题，我们强调将内容与稀疏特征相结合以构建更优检索系统的重要性。对于所有笔记，我们按时间顺序附上图片列表，其中列表中的第一张图是封面，对用户的点击行为具有重要影响。由于视频内容在信息上存在冗余，我们除了封面外，还从关键帧中等距地抽取图像。所有图像均以WebP格式压缩，该格式通常在不损失图像质量的前提下，比JPEG平均多压缩30%。

3.3 潜在任务

根据现有特征和信息，我们在表4中列出了麒麟可能支持的任务范围。首先，麒麟能够实现基于内容的检索与重排序，适用于搜索和推荐场景。通过将图像融入用户意图或笔记内容编码中，还可进一步探索多模态搜索与推荐系统。在异构结果页面中，相比传统的纯文本页面，用户行为偏差往往更为明显。因此，无偏学习排序[3, 7]对于提升系统的公平性与可持续性至关重要。其次，通过利用不同场景下的多种用户反馈标签，可有效训练多任务或多场景学习框架[2, 8, 46]。除了联合学习外，一个场景的信息也可选择性地应用于增强另一个场景。例如，推荐场景中的用户行为可被整合到

搜索排序算法以更好地建模用户偏好[47]。由于我们的数据集涉及用户对不同模块和服务的交互行为，可能存在值得进一步探索的有趣异质性用户行为模式。其他一些任务包括检索增强生成（RAG）的预训练后处理[20]、查询性能预测（QPP）[5]、查询（意图）推荐[42]、多模态对齐、规模定律拟合[17]，以及使用多模态大语言模型作为评判者[29]。具体而言，第3.1节中基于大语言模型的数据过滤过程可被视为“大语言模型作为评判者”的一个实例。

最后但同样重要的是，当加入精确的人工标注后，麒麟可作为半成品基准，用于支持更多任务，例如用户满意度建模、实体增强搜索、多模态RAG评估等。

4 原始数据分析

本节主要介绍麒麟的初步数据分析，主要包括四个部分：1）人口统计特征，2）参与度与结果分布，3）服务间的转换情况，以及4）查询分析。

4.1 人口统计学

根据IP地理位置数据，15,482名用户来自87个以上的国家和地区，主要包括中国（84.32%）、安道尔（1.45%）、澳大利亚（1.22%）、冰岛（1.19%）、马来西亚（1.14%），以及日本、韩国、美国、英国、加拿大、爱尔兰、法国、新加坡、奥地利和德国。其中女性用户占76.53%，男性用户占其余比例，性别比略高于该APP的平均水平。这可能是因为我们保留了一定比例触发DQA模块的搜索请求，而女性用户在这些请求中的参与度更高。大多数用户为青年和中年人群，年龄集中在16至40岁之间（占74.5%），另有少量用户年龄低于16岁（3.88%）或超过40岁（7.27%）。从平台分布来看，iOS和Android分别占比53.56%和38.79%，其余用户通过桌面网站或其他移动操作系统（如鸿蒙系统）发起请求。

4.2 参与度与结果分布

基于麒麟数据集，本节旨在分析以下三个方面：1）不同场景下的用户参与度，2）用户行为偏差，以及3）结果类型的分布情况。

为了探究用户参与度，我们选取了两组情景进行对比：S（搜索）与R（推荐），以及S+DQA（带DQA的搜索）与S-DQA（不带DQA的搜索）。如表5所示，我们得出以下几点发现。首先，与搜索相比，用户在推荐场景中点击结果较少，但参与率更高，唯一的例外是收藏行为。由于搜索时用户意图更明确，他们可能会浏览更多结果以寻找相关或有用的内容，从而导致更高的浏览深度和点击次数。一旦找到有用的笔记，用户通常会将其保存至个人收藏，以备将来使用。总体而言，在推荐过程中，用户意图较为多样且模糊，他们可能只是点击一些有趣的笔记来消磨时间，并通常从一个视频快速滑动到另一个视频。因此，推荐场景中的用户在原始结果页面上浏览的结果较少，但在嵌入式尖叫内容中则会浏览并点赞更多结果。通过比较右侧

表5：不同场景下的用户参与度，其中S-DQA表示未触发DQA模块的搜索请求，S+DQA表示触发了DQA模块的搜索请求。注意，点赞率和收藏率等参与率是基于条件概率 $P(\text{engage} = 1 | \text{click} = 1)$ 计算得出的。

	S	R	S-DQA	S+DQA
平均浏览深度	22.75	18.80	23.41	10.61
平均首次点击排名	3.01	4.97	3.03	2.50
平均点击次数	3.88	3.67	3.99	2.50
点击率	21.01%	24.13%	21.02%	20.73%
点赞	4.11%	7.07%	4.19%	1.29%
回收率	1.87%	1.47%	1.88%	1.26%
分享率	0.57%	0.63%	0.57%	0.52%
如何评分	0.32%	0.99%	0.32%	0.21%
# 示例	57,188	94,552	54,256	2,932

通过对比两列数据，我们发现DQA模块对用户行为有显著影响。当提供直接答案时，用户仅点击顶部少数几个高相关性的笔记（即首次点击位置靠前），且与笔记的互动明显减少。这可能有两个原因：1）触发DQA模块的查询通常为事实性问题，用户的信息需求可通过少量笔记轻松满足；2）DQA模块通过提供带参考笔记的直接答案，节省了用户搜索和总结有用信息的精力。鉴于用户行为存在如此显著差异，有必要进一步研究如何对原始结果进行排序以及设计结果页面布局，以提升用户的搜索体验。

接下来，我们在和图3(b)中分别绘制了不同排名位置和会话位置下的点击率（CTR）。无论是搜索还是推荐，随着排名位置的上升，CTR均呈现下降趋势，这种现象通常被称为位置偏差。在推荐场景中，CTR的衰减速度相对较慢，表明用户的浏览行为可能比搜索更随机，而搜索用户更倾向于点击靠前的结果。值得注意的是，在搜索和推荐中，第三位和第六位的位置分布出现了明显的下降。我们推测，这些位置展示商业广告笔记的概率较高，因此用户点击意愿较低。从会话维度来看，当用户在一个APP级会话内发起更多请求时，点击率同样呈现出衰减趋势，但这种衰减在会话层面更为平缓。由于搜索用户处于试错过程中，其CTR曲线在会话末尾的下降速度明显快于推荐场景。用户疲劳或满意度等因素可能导致这种会话偏差，即用户的累积成本或收益已达到上限，因此在会话后期更不愿意点击某个结果。

对于结果类型，我们仅考虑图文笔记和视频笔记。我们首先计算每种笔记类型在排名位置上的分布比例。如和图3(d)所示，在两种搜索与推荐（S&R）场景中，视频笔记的比例均先上升后趋于平稳。通过对比两图可以明显看出，视频笔记在推荐中获得了更多的曝光。这一现象可能由用户与系统之间持续的交互循环所导致。首先，

^{3A} commercial note is an image-text note or a video note with a product or advertisement, only accounting for a tiny proportion of the data.




图3：在搜索和推荐场景中，两种结果类型的排名位置所对应的点击位置偏差、会话偏差、结果类型分布及点击率。

用户在使用推荐服务时，更倾向于通过观看视频来消磨时间。经过一段时间后，推荐系统可能已学习到这一模式，并自动将更多视频内容排在前列。用户持续点击这些视频笔记，导致搜索场景与推荐场景之间的曝光结构出现显著差异。通常情况下，无论在哪个场景中，用户对图文笔记的点击率都更高（见图3(e)和3(f)）。我们推测主要有两个原因：浏览所需努力程度的差异以及用户环境的限制。视频笔记通常需要更长时间完成观看，每屏提供的文字信息较少，且可能在周围环境中产生干扰噪音。这些局限性使得用户在大多数情况下更倾向于点击图文笔记。然而，在某些特定情境下，例如娱乐需求或需要获取详细片段级信息时，视频笔记则能带来更大优势。因此，未来应进一步研究如何根据用户的特定意图或请求条件选择合适的笔记类型，以提升用户满意度。

表6：用户转换分析。S和R分别代表搜索和推荐。

	S→S	R→S	R→R	S→R
比例	34.88%	2.95%	59.32%	2.84%
平均点击次数	4.0014	3.9782	2.9745	4.4466
点击率	20.18%	22.98%	23.20%	25.01%
# 示例	29,295	2,476	49,815	2,387

表7：查询长度分布及相应的用户参与度。注意，颜色越深表示点击率（CTR）或平均点击次数越高。

	比例	点击率	平均点击次数
长度≤3	0.32%	0.1967	2.9892
长度=4	13.64%	0.1962	4.0276
长度=5	13.94%	0.2047	3.9303
长度=6	17.27%	0.2051	4.0338
长度=7	14.07%	0.2111	3.9446
长度=8	12.42%	0.2150	3.8180
长度=9	9.54%	0.2199	3.6971
长度=10	6.89%	0.2272	3.7497
长度>10	11.91%	0.2216	3.7010

4.3 服务之间的过渡

本节展示了用户在搜索与推荐服务之间的转换行为。由于应用层会话中可能存在用户意图转换的噪声，我们重新定义了会话概念以实现更准确的转换分析：若同一用户发出的两个请求（搜索或推荐）的起始时间戳间隔在30分钟以内，则认为它们属于同一个会话。如表6所示，用户主要在搜索服务内部或推荐服务内部进行转换，但也存在一定比例的从推荐到搜索（2.95%）和从搜索到推荐（2.84%）的跨服务转换。当用户从推荐服务转向搜索时，其点击搜索结果的点击率通常高于一般搜索情况下的点击率；同样，当用户从搜索转至推荐时，对所展示结果的互动程度也更高。这表明，将这些转换行为纳入考量，有助于更精准地建模用户偏好[46]。

4.4 查询分析

接下来，我们对麒麟数据集中的搜索查询进行分析，包括基于字符的查询长度、查询重述类型以及搜索来源。首先，我们计算了不同长度查询所占的比例，并进一步比较了这些查询组下的用户参与度。从表7可以看出，大多数查询包含4到8个字符，在此范围内用户倾向于点击更多结果（即最右侧列的中间注意力部分）。这类查询能够清晰表达用户意图，且难度适中，使搜索引擎能返回更相关的结果。有趣的是，随着查询长度增加，点击率持续上升。除了较长的查询通常具有更明确的意图和更匹配的结果外，用户在提出较长查询时（例如任务导向型查询）往往更希望获得满意的答案，因此他们更有可能点击搜索结果。

表8: 不同查询重述类型的示例。重述操作的总数为29,875。

类型	提案	示例
添加	13.57%	广州批发→广州批发市场 五大文明→五大文明发源地
删除	2.53%	知识产权设计插件→知识产权设计 农业经营模式分析→农业经营模式
改变	47.16%	文案的破碎感→文案的自由松弛感(脆弱感的写作→自由放松的写作) 将数据分为三分位→四分位间距
重复	7.57%	usmtekun美食→usmtekun美食(马来西亚一家名为usm tekun的咖啡馆的特色美食) 脸部画法→脸部画法(绘制面部的技巧)
其他人	29.17%	相机镜头进灰→适马56mm (the camera lens has dust in it→SIGMA 56mm camera lens) 挡脸怎么弄好看→文案配照片 (cover the face in a visually appealing way→match captions with photos)

其次, 我们旨在探索用户的查询重述行为。根据[9, 27]的方法, 我们基于连续两次查询QT-1和QT之间的句法关系, 定义了五种重述行为类型。设 $+QT = \{W|W \in W(QT), W \notin W(QT-1)\}$, $-QT = \{W|W \notin W(QT), W \in W(QT-1)\}$, 以及 $\cap Q_T = \{W|W \in W(QT), W \in W(QT-1)\}$, 其中W表示一个词, $W(\cdot)$ 表示词的集合。我们将添加、删除、修改、重复及其他类型的重述行为表达方式标准化如下:

$$Add : +\Delta q_t \neq \emptyset, -\Delta q_t = \emptyset; \quad (1)$$

$$Delete : +\Delta q_t = \emptyset, -\Delta q_t \neq \emptyset; \quad (2)$$

$$Change : +\Delta q_t \neq \emptyset, -\Delta q_t \neq \emptyset, \cap q_t \neq \emptyset; \quad (3)$$

$$Repeat : +\Delta q_t = \emptyset, -\Delta q_t = \emptyset, \cap q_t \neq \emptyset; \quad (4)$$

$$Others : +\Delta q_t \neq \emptyset, -\Delta q_t \neq \emptyset, \cap q_t = \emptyset; \quad (5)$$

基于上述定义以及第4.3节中获得的S→S会话, 我们在表8中展示了各类句法查询重述的比例及其对应示例。其中, “修改”、“添加”和“其他”三类占有所有样本的约90%, 这与通用搜索中的先前研究结果[9]一致。各类别分布较为均衡, 表明用户在小红书上的搜索行为具有较高的复杂性。当用户的搜索意图趋于具体或泛化时, 他们可能会根据上一次查询添加或删除关键词。例如, 在输入“五大文明”后, 用户可能对这些文明的起源产生兴趣, 并随后提交第二次查询。当用户沉浸在自发的信息获取流程中时, 他们对系统的信任度和粘性可能显著增强。因此, 提升整个搜索与推荐系统的情境感知用户体验将至关重要。

除了查询重述外, 查询来源还可用于建模用户状态的变化。根据界面功能, 数十个条目可大致分为八类, 如表9所示。我们发现, 约一半的查询来自自动补全模块, 这与谷歌和百度等通用搜索引擎存在显著差异, 在这些搜索引擎中, 用户通常通过输入框自行输入查询[9]。约6%的查询来自历史记录, 表明用户在一段时间内可能具有相似的搜索意图。此外, 用户还会点击结果页面或笔记中显示的查询建议。通过建模未来的意图, 并在合适的时间向用户推荐潜在查询, 可进一步提升用户参与度。

表9: 查询源的定义与分析。

	名字	定义	提案
1	主动搜索	使用搜索输入框	33.70%
2	自动补全	使用自动补全	50.97%
3	搜索历史	重新查看搜索历史	5.78%
4	建议一	点击结果页面的建议	3.97%
5	建议二	点击结果中的建议	3.02%
6	搜索筛选	使用搜索 filters [†]	1.37%
7	热门榜单	点击热点列表	0.63%
8	其他人	其他所有类型	0.55%

[†] 包括“最新笔记”、“仅视频笔记”等筛选条件

5 实验

在本节中, 我们分别报告了基线方法在搜索、推荐和DQA任务上的性能表现。由于篇幅限制, 我们未考虑多个任务的联合优化, 将其留作未来的工作。

5.1 搜索与推荐

我们将所有公开样本按时间顺序排序, 并以11:1的小时比例划分为训练集和测试集, 即晚上22:00之后的样本作为测试样本。基线模型包括BM25、BERT[14]双编码器、BERT交叉编码器、DCN-V2[50]以及视觉语言模型(VLM) [62]。在推荐任务中, 我们使用用户最近点击笔记的标题拼接而成的伪查询来建模用户偏好。对于BM25、BERT双编码器和BERT交叉编码器, 输入包含查询文本、笔记标题和笔记内容。此外, VLM还将封面图像融入笔记编码中。至于DCN-V2, 除了由预训练的BERT双编码器生成的查询和笔记(标题+内容)嵌入(均值池化后的隐藏状态)外, 我们还利用了Qilin提供的多种稠密特征和上下文信号, 例如最近点击的笔记。我们将DCN-V2的可训练参数量扩展至0.13B, 与BERT-base-chinese模型(0.1B)相当。除VLM外, 其余模型均采用端到端方式训练。我们选用经过4位量化处理的Qwen2-VL-7B-Instruct [62]作为视觉语言模型(VLM)的主干, 并采用LoRA [26]进行训练, 这是一种参数高效的微调方法。通过将lora_rank设置为16, 仅调整约1000万VLM参数, 以确保比较的公平性。所有实验细节均可在上述发布的代码仓库中找到。

⁴As Qilin is Chinese-centric, we count a character as a word.

表10: 不同方法在搜索和推荐性能上的比较。

模型	搜索			
	MRR@10	MRR@100	MAP@10	MAP@100
BM25	0.3388	0.3467	0.2399	0.3139
BERT _{BI}	0.5320	0.5359	0.3855	0.4536
BERT交叉	0.5336	0.5386	0.3848	0.4533
DCN-V2	0.5600	0.5653	0.4014	0.4683
VLM	0.5523	0.5563	0.3937	0.4601
模型	推荐			
	MRR@10	MRR@100	MAP@10	MAP@100
BM25	0.5379	0.5418	0.3933	0.4634
BERT _{BI}	0.6067	0.6087	0.4548	0.5183
BERT交叉	0.6346	0.6362	0.4786	0.5394
DCN-V2	0.6307	0.6321	0.4651	0.5278
VLM	0.6394	0.6409	0.4890	0.5477

对于评估指标, 我们选择平均倒数排名 (MRR) 和平均准确率 (MAP), 其公式可表示为:

$$MRR@K = \frac{1}{N} \sum_i \frac{\mathbb{I}(r_i \leq K)}{r_i} \quad (6)$$

$$MAP@K = \frac{1}{N} \sum_i \frac{1}{R_i} \sum_k P_{i,k} \cdot \mathbb{I}(rel_{i,k} = 1) \quad (7)$$

其中, N 表示测试样本的总数, RI 表示重排序列表中第一个正例结果的排名位置。 RI 和 PI , K 分别表示第 i 个样本的相关结果数量以及在 k 位置处的精确率指标。至于 REL_i, K , 为简便起见, 我们使用点击作为二元相关性标签。

所有结果均列于表10中。在搜索和推荐任务中, BERT交叉编码器的表现均优于双编码器, 这与现有研究的发现一致。显式的查询与文档交互有助于模型更好地学习相关性匹配。通过引入视觉信息, VLM在两项任务上进一步提升了性能, 表明在用户建模和笔记表示中考虑笔记图像具有有效性。与这些预训练模型相比, DCN-V2在两个任务中均展现出具有竞争力的表现。它综合了用户历史、基于ID的稀疏特征、稠密特征以及预训练的语义嵌入, 因此在搜索排序任务中表现最佳。然而, 在推荐任务中, DCN-V2的优势相对较小, 可能主要有两个原因: 1) 在我们的设置中, 推荐所使用的伪查询已对用户偏好进行了总结, 从而缩小了DCN-V2与其他方法之间的差距; 2) 推荐任务对模型的鲁棒性要求更高, 需要应对分布外问题。由于DCN-V2严重依赖稀疏特征, 且缺乏对语义信号匹配的深度建模, 因此在推荐效果上可能有所不足。总体而言, 实验结果表明, 考虑多模态特征和丰富的上下文信号对于优化检索系统具有巨大潜力。

5.2 DQA

对于DQA任务, 所有用户参与的答案均被视为评估的标准答案。随后, 我们采用五种流行的LLM模型

表11: 不同大语言模型在检索增强生成 (RAG) 性能上的对比。

生成/检索		NA	BM25	BERT _{BI}	甲骨文
红唇	GPT3.5	0.332	0.388	0.390	0.424
	GPT-4o-mini	0.316	0.384	0.380	0.429
	Qwen2.5-72B	0.342	0.396	0.396	0.436
	Llama3.3-70B	0.290	0.349	0.347	0.396
	GLM4	0.318	0.363	0.366	0.401
BERTScore	GPT3.5	0.708	0.725	0.722	0.748
	GPT-4o-mini	0.710	0.729	0.728	0.754
	Qwen2.5-72B	0.714	0.725	0.724	0.752
	Llama3.3-70B	0.699	0.730	0.727	0.760
	GLM4	0.701	0.715	0.713	0.739

(GPT3.5 [1]、GPT4o-mini [1]、Qwen2.5-72B-Instruct [63]、Llama3.3-70B-Instruct [15]、GLM4 [21]) 在零样本设置下通过标准RAG流程直接生成答案, 并基于标准答案评估其质量。如表11所示, 我们在四种条件下测试了这些大语言模型的生成性能: 1) 不使用参考文档 (NA), 2) 使用BM25检索的前五篇文档, 3) 使用BERT双编码器检索的前五篇文档, 4) 使用麒麟 (Oracle) 提供的参考文档。为综合评估语法和语义层面的答案质量, 我们采用ROUGE-L和BERTScore (F1) 作为评价指标。从表中可得出若干观察结果。首先, 生成性能按以下顺序递增: $NA < BM25 < BERT_{BI} < Oracle$, 这与我们的预期一致。通过对比发现, Qwen2.5在ROUGE-L得分上表现最高, 而Llama在语义匹配方面优于其他模型, 表明不同大语言模型的能力侧重点可能存在差异。

6 结论

在本研究中, 我们提出了一种全新的多模态搜索与推荐 (S&R) 数据集Qilin。该数据集包含15,482名用户的APP级会话数据, 为异构结果提供了文本和图像内容。此外, 我们还收集了丰富的上下文信号, 如查询来源、多种用户反馈以及深度问答 (DQA) 细节, 以支持各类信息检索相关任务的研究。通过对人口统计特征、用户参与度、结果分布及查询模式等维度的全面数据分析, 我们揭示了多项有助于提升S&R系统性能的多角度洞察。为了更好地验证其应用潜力, 我们在Qilin上开展了搜索、推荐和深度问答的初步实验。我们相信, 这些发现与见解将对构建更先进的多模态检索系统具有重要价值。

参考文献

- [1] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Floren-cia Leoni Aleman, Diogo Almeida, Janko Altmenschmidt, Sam Altman, Shyamal Anadkat, et al. 2023. Gpt-4 technical report. arXiv preprint arXiv:2303.08774 (2023).
- [2] Wasi Uddin Ahmad, Kai-Wei Chang, and Hongning Wang. 2019. Context attentive document ranking and query suggestion. In Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval. 385–394.
- [3] Qingyao Ai, Keping Bi, Cheng Luo, Jiafeng Guo, and W Bruce Croft. 2018. Unbi-ased learning to rank with unbiased propensity estimation. In The 41st interna-tional ACM SIGIR conference on research & development in information retrieval. 385–394.
- [4] Qingyao Ai, Yongfeng Zhang, Keping Bi, Xu Chen, and W Bruce Croft. 2017. Learning a hierarchical embedding model for personalized product search. In Proceedings of the 40th International ACM SIGIR Conference on Research and Development in Information Retrieval. 645–654.
- [5] Negar Arabzadeh, Maryam Khodabakhsh, and Ebrahim Bagheri. 2021. BERT-QPP: contextualized pre-trained transformers for query performance prediction. In Proceedings of the 30th ACM International Conference on Information & Knowledge Management. 2857–2861.
- [6] Saeid Balaneshin-kordan and Alexander Kotov. 2018. Deep neural architecture for multi-modal retrieval based on joint embedding space for text and images. In Proceedings of the Eleventh ACM International Conference on Web Search and Data Mining. 28–36.
- [7] Jia Chen, Haitao Li, Weihang Su, Qingyao Ai, and Yiqun Liu. 2023. THUIR at WSDM Cup 2023 Task 1: Unbiased Learning to Rank. arXiv preprint arXiv:2304.12650 (2023).
- [8] Jia Chen, Jiaxin Mao, Yiqun Liu, Ziyi Ye, Weizhi Ma, Chao Wang, Min Zhang, and Shaoping Ma. 2021. A hybrid framework for session context modeling. ACM Transactions on Information Systems (TOIS) 39, 3 (2021), 1–35.
- [9] Jia Chen, Jiaxin Mao, Yiqun Liu, Fan Zhang, Min Zhang, and Shaoping Ma. 2021. Towards a better understanding of query reformulation behavior in web search. In Proceedings of the web conference 2021. 743–755.
- [10] Jia Chen, Jiaxin Mao, Yiqun Liu, Min Zhang, and Shaoping Ma. 2019. TianGong ST: A new dataset with large-scale refined real-world web search sessions. In Proceedings of the 28th ACM International Conference on Information and Knowl-edge Management. 2485–2488.
- [11] Jia Chen, Jiaxin Mao, Yiqun Liu, Min Zhang, and Shaoping Ma. 2020. A context-aware click model for web search. In Proceedings of the 13th International Confer-ence on Web Search and Data Mining. 88–96.
- [12] Aleksandr Chuklin, Ilya Markov, and Maarten De Rijke. 2022. Click models for web search. Springer Nature.
- [13] Arnon Dagan, Ido Guy, and Slava Novgorodov. 2021. An image is worth a thousand terms? analysis of visual e-commerce search. In Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. 102–112.
- [14] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2018. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. arXiv: 1810.04805 [cs.CL]
- [15] Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Amy Yang, Angela Fan, et al. 2024. The llama 3 herd of models. arXiv preprint arXiv:2407.21783 (2024).
- [16] Yixing Fan, Xiaohui Xie, Yinqiong Cai, Jia Chen, Xinyu Ma, Xiangsheng Li, Ruqing Zhang, Jiafeng Guo, et al. 2022. Pre-training methods in information retrieval. Foundations and Trends® in Information Retrieval 16, 3 (2022), 178–317.
- [17] Yan Fang, Jingtao Zhan, Qingyao Ai, Jiaxin Mao, Weihang Su, Jia Chen, and Yiqun Liu. 2024. Scaling laws for dense retrieval. In Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. 1339–1349.
- [18] Andrea Frome, Greg S Corrado, Jon Shlens, Samy Bengio, Jeff Dean, Marc Aurelio Ranzato, and Tomas Mikolov. 2013. Devise: A deep visual-semantic embedding model. Advances in neural information processing systems 26 (2013).
- [19] Chongming Gao, Shijun Li, Wenqiang Lei, Jiawei Chen, Biao Li, Peng Jiang, Xiangnan He, Jiaxin Mao, and Tat-Seng Chua. 2022. KuaiRec: A fully-observed dataset and insights for evaluating recommender systems. In Proceedings of the 31st ACM International Conference on Information & Knowledge Management. 540–550.
- [20] Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, and Haofen Wang. 2023. Retrieval-augmented generation for large language models: A survey. arXiv preprint arXiv:2312.10997 (2023).
- [21] Team GLM, Aohan Zeng, Bin Xu, Bowen Wang, Chenhui Zhang, Da Yin, Dan Zhang, Diego Rojas, Guanyu Feng, Hanlin Zhao, et al. 2024. Chatglm: A fam-ily of large language models from glm-130b to glm-4 all tools. arXiv preprint arXiv:2406.12793 (2024).
- [22] Yu Gong, Xusheng Luo, Kenny Q Zhu, Wenwu Ou, Zhao Li, and Lu Duan. 2019. Automatic generation of chinese short product titles for mobile display. In Pro-ceedings of the AAAI Conference on Artificial Intelligence, Vol. 33. 9460–9465.
- [23] Yangyang Guo, Zhiyong Cheng, Liqiang Nie, Xin-Shun Xu, and Mohan Kankan-halli. 2018. Multi-modal preference modeling for product search. In Proceedings of the 26th ACM international conference on Multimedia. 1865–1873.
- [24] Ruining He and Julian McAuley. 2016. Ups and downs: Modeling the visual evolution of fashion trends with one-class collaborative filtering. In proceedings of the 25th international conference on world wide web. 507–517.
- [25] Micah Hodosh, Peter Young, and Julia Hockenmaier. 2013. Framing image de-scription as a ranking task: Data, models and evaluation metrics. Journal of Artificial Intelligence Research 47 (2013), 853–899.
- [26] Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. 2021. Lora: Low-rank adaptation of large language models. arXiv preprint arXiv:2106.09685 (2021).
- [27] Jeff Huang and Efthimis N Efthimiadis. 2009. Analyzing and evaluating query reformulation strategies in web search logs. In Proceedings of the 18th ACM conference on Information and knowledge management. 77–86.
- [28] Katrien Laenen, Susana Zoghbi, and Marie-Francine Moens. 2018. Web search of fashion items with multimodal querying. In Proceedings of the eleventh ACM international conference on web search and data mining. 342–350.
- [29] Haitao Li, Qian Dong, Junjie Chen, Huixue Su, Yujia Zhou, Qingyao Ai, Ziyi Ye, and Yiqun Liu. 2024. LLMs-as-Judges: A Comprehensive Survey on LLM-based Evaluation Methods. arXiv preprint arXiv:2412.05579 (2024).
- [30] Jianghao Lin, Bo Chen, Hangyu Wang, Yunjia Xi, Yanru Qu, Xinyi Dai, Kangning Zhang, Ruiming Tang, Yong Yu, and Weinan Zhang. 2024. ClickPrompt: CTR Models are Strong Prompt Generators for Adapting Language Models to CTR Prediction. In Proceedings of the ACM on Web Conference 2024. 3319–3330.
- [31] Jiongnan Liu, Zhicheng Dou, Guoyu Tang, and Sulong Xu. 2023. Jdsearch: A personalized product search dataset with real queries and full interactions. In Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2945–2952.
- [32] Meng Liu, Xiang Wang, Liqiang Nie, Xiangnan He, Baoquan Chen, and Tat-Seng Chua. 2018. Attentive moment retrieval in videos. In The 41st international ACM SIGIR conference on research & development in information retrieval. 15–24.
- [33] Shilei Liu, Lin Li, Jun Song, Yonghua Yang, and Xiaoyi Zeng. 2023. Multimodal pre-training with self-distillation for product understanding in e-commerce. In Proceedings of the Sixteenth ACM International Conference on Web Search and Data Mining. 1039–1047.
- [34] Xinyi Liu, Wanxian Guan, Lianyun Li, Hui Li, Chen Lin, Xubin Li, Si Chen, Jian Xu, Hongbo Deng, and Bo Zheng. 2022. Pretraining Representations of Multi-modal Multi-query E-commerce Search. In Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 3429–3437.
- [35] Yiqun Liu, Kaushik Rangadurai, Yunzhong He, Siddarth Malreddy, Xunlong Gui, Xiaoyi Liu, and Fedor Borisjuk. 2021. Que2search: fast and accurate query and document understanding for search at facebook. In Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining. 3376–3384.
- [36] Xin Luo, Ye Wu, and Xin-Shun Xu. 2018. Scalable supervised discrete hashing for large-scale search. In Proceedings of the 2018 World Wide Web Conference. 1603–1612.
- [37] Junhua Mao, Wei Xu, Yi Yang, Jiang Wang, Zhiheng Huang, and Alan Yuille. 2015. Deep Captioning with Multimodal Recurrent Neural Networks (m-RNN). arXiv:1412.6632 [cs.CV] <https://arxiv.org/abs/1412.6632>
- [38] Benjamin M Marlin and Richard S Zemel. 2009. Collaborative prediction and ranking with non-random missing data. In Proceedings of the third ACM conference on Recommender systems. 5–12.
- [39] Julian McAuley, Christopher Targett, Qinfeng Shi, and Anton Van Den Hengel. 2015. Image-based recommendations on styles and substitutes. In Proceedings of the 38th international ACM SIGIR conference on research and development in information retrieval. 43–52.
- [40] Lianhai Miao, Da Cao, Juntao Li, and Weili Guan. 2020. Multi-modal product title compression. Information Processing & Management 57, 1 (2020), 102123.
- [41] Tri Nguyen, Mir Rosenberg, Xia Song, Jianfeng Gao, Saurabh Tiwary, Rangan Majumder, and Li Deng. 2016. Ms marco: A human-generated machine reading comprehension dataset. (2016).
- [42] Umut Ozertem, Olivier Chapelle, Pinar Donmez, and Emre Velipasoglu. 2012. Learning to suggest: a machine learning framework for ranking query sugges-tions. In Proceedings of the 35th international ACM SIGIR conference on Research and development in information retrieval. 25–34.
- [43] Bryan A Plummer, Liwei Wang, Chris M Cervantes, Juan C Caicedo, Julia Hock-enmaier, and Svetlana Lazebnik. 2015. Flickr30k entities: Collecting region-to-phrase correspondences for richer image-to-sentence models. In Proceedings of the IEEE international conference on computer vision. 2641–2649.
- [44] Leigang Qu, Meng Liu, Jianlong Wu, Zan Gao, and Liqiang Nie. 2021. Dynamic modality interaction modeling for image-text retrieval. In Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. 1104–1113.
- [45] Zhaochun Ren, Xiangnan He, Dawei Yin, Maarten de Rijke, et al. 2024. Informa-tion Discovery in E-commerce. Foundations and Trends® in Information Retrieval 18, 4-5 (2024), 417–690.

- [46] Teng Shi, Zihua Si, Jun Xu, Xiao Zhang, Xiaoxue Zang, Kai Zheng, Dewei Leng, Yanan Niu, and Yang Song. 2024. UniSAR: Modeling User Transition Behaviors between Search and Recommendation. In Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. 1029–1039.
- [47] Zihua Si, Zhongxiang Sun, Xiao Zhang, Jun Xu, Xiaoxue Zang, Yang Song, Kun Gai, and Ji-Rong Wen. 2023. When search meets recommendation: Learning disentangled search representation for recommendation. In Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval. 1313–1323.
- [48] Richard Socher, Andrej Karpathy, Quoc V Le, Christopher D Manning, and Andrew Y Ng. 2014. Grounded compositional semantics for finding and describing images with sentences. *Transactions of the Association for Computational Linguistics* 2 (2014), 207–218.
- [49] Zhongxiang Sun, Zihua Si, Xiaoxue Zang, Dewei Leng, Yanan Niu, Yang Song, Xiao Zhang, and Jun Xu. 2023. KuaiSAR: A Unified Search And Recommendation Dataset. In Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. 5407–5411.
- [50] Ruoxi Wang, Rakesh Shivanna, Derek Cheng, Sagar Jain, Dong Lin, Lichan Hong, and Ed Chi. 2021. Dcn v2: Improved deep & cross network and practical lessons for web-scale learning to rank systems. In Proceedings of the web conference 2021. 1785–1797.
- [51] Wei Wang, Xiaoyan Yang, Beng Chin Ooi, Dongxiang Zhang, and Yueting Zhuang. 2016. Effective deep learning-based multi-modal retrieval. *The VLDB Journal* 25 (2016), 79–101.
- [52] Xiaohua Wang, Zhenghua Wang, Xuan Gao, Feiran Zhang, Yixin Wu, Zhibo Xu, Tianyuan Shi, Zhengyuan Wang, Shizheng Li, Qi Qian, et al. 2024. Searching for best practices in retrieval-augmented generation. In Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. 17716–17736.
- [53] Yunxiao Wang, Meng Liu, Yinwei Wei, Zhiyong Cheng, Yinglong Wang, and Liqiang Nie. 2022. Siamese alignment network for weakly supervised video moment retrieval. *IEEE Transactions on Multimedia* 25 (2022), 3921–3933.
- [54] Zihao Wang, Xihui Liu, Hongsheng Li, Lu Sheng, Junjie Yan, Xiaogang Wang, and Jing Shao. 2019. Camp: Cross-modal adaptive message passing for text-image retrieval. In Proceedings of the IEEE/CVF international conference on computer vision. 5764–5773.
- [55] Cong Wei, Yang Chen, Haonan Chen, Hexiang Hu, Ge Zhang, Jie Fu, Alan Ritter, and Wenhui Chen. 2025. Uniir: Training and benchmarking universal multimodal information retrievers. In *European Conference on Computer Vision*. Springer, 387–404.
- [56] Jiwei Wei, Yang Yang, Xing Xu, Xiaofeng Zhu, and Heng Tao Shen. 2021. Universal weighting metric learning for cross-modal retrieval. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 44, 10 (2021), 6534–6545.
- [57] Qingyun Wu, Hongning Wang, Liangjie Hong, and Yue Shi. 2017. Returning is believing: Optimizing long-term user engagement in recommender systems. In Proceedings of the 2017 ACM on Conference on Information and Knowledge Management. 1927–1936.
- [58] Zhijing Wu, Mark Sanderson, B Barla Cambazoglu, W Bruce Croft, and Falk Scholer. 2020. Providing direct answers in search results: A study of user behavior. In Proceedings of the 29th acm international conference on information & knowledge management. 1635–1644.
- [59] Xiaohui Xie, Qian Dong, Bingning Wang, Feiyang Lv, Ting Yao, Weinan Gan, Zhijing Wu, Xiangsheng Li, Haitao Li, Yiqun Liu, et al. 2023. T2ranking: A large-scale chinese benchmark for passage ranking. In Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2681–2690.
- [60] Xiaohui Xie, Yiqun Liu, Xiaochuan Wang, Meng Wang, Zhijing Wu, Yingying Wu, Min Zhang, and Shaoping Ma. 2017. Investigating examination behavior of image search users. In Proceedings of the 40th international acm sigir conference on research and development in information retrieval. 275–284.
- [61] Xiaohui Xie, Jiaxin Mao, Yiqun Liu, Maarten de Rijke, Qingyao Ai, Yufei Huang, Min Zhang, and Shaoping Ma. 2019. Improving web image search with con-textual information. In Proceedings of the 28th ACM international conference on information and knowledge management. 1683–1692.
- [62] An Yang, Baosong Yang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Zhou, Chengpeng Li, Chengyuan Li, Dayiheng Liu, Fei Huang, Guanting Dong, Hao-ran Wei, et al. 2024. Qwen2 Technical Report. arXiv:2407.10671 [cs.CL] <https://arxiv.org/abs/2407.10671>
- [63] An Yang, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chengyuan Li, Dayiheng Liu, Fei Huang, Haoran Wei, et al. 2024. Qwen2.5 technical report. arXiv preprint arXiv:2412.15115 (2024).
- [64] Fan Yang, Ajinkya Kale, Yury Bubnov, Leon Stein, Qiaosong Wang, Hadi Kiapour, and Robinson Pira-muthu. 2017. Visual search at ebay. In Proceedings of the 23rd ACM SIGKDD international conference on knowledge discovery and data mining. 2101–2110.
- [65] Chao Zhang, Shiwei Wu, Haoxin Zhang, Tong Xu, Yan Gao, Yao Hu, and En-hong Chen. 2024. NoteLLM: A Retrievable Large Language Model for Note Recommendation. In Companion Proceedings of the ACM on Web Conference 2024. 170–179.
- [66] Hanwang Zhang, Zheng-Jun Zha, Yang Yang, Shuicheng Yan, Yue Gao, and Tat-Seng Chua. 2013. Attribute-augmented semantic hierarchy: towards bridging semantic gap and intention gap in image retrieval. In Proceedings of the 21st ACM international conference on Multimedia. 33–42.
- [67] Yanhao Zhang, Pan Pan, Yun Zheng, Kang Zhao, Yingya Zhang, Xiaofeng Ren, and Rong Jin. 2018. Visual search at alibaba. In Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining. 993–1001.
- [68] Lei Zhu, Xu Lu, Zhiyong Cheng, Jingjing Li, and Huaxiang Zhang. 2020. Deep collaborative multi-view hashing for large-scale image search. *IEEE Transactions on Image Processing* 29 (2020), 4643–4655.